Basic Statistical Concepts 2026 Spring

第 1 讲：基本统计概念

估计、置信区间、假设检验

整理：AmphiLuminism Fudan University

本讲摘要

本讲主要回顾在概率论与数理统计中学过的统计学概念与方法。

1.1 统计量

对于一组数据，我们可以用统计量来描述这组数据，包括均值、中位数和四分位数、方差、标准差。

定义

定义 1.1.1 (均值 Mean)**.** 给定一组数据 $X_1, X_2, ..., X_n$，则

$$\bar{X} = \frac{\sum_{i=1}^{n} X_i}{n}$$

称为这组数据的均值。

定义

定义 1.1.2 (中位数 Median 和四分位数 Quartiles)**.** 给定一组数据 $X_1, X_2, ..., X_n$，将其从小到大排列，

(1) 如果数据的个数 n 为奇数，则称第 $\frac{n+1}{2}$ 个数为这组数据的中位数；

(2) 如果数据的个数 n 为偶数，则称第 $\frac{n}{2}$ 个数和第 $\frac{n}{2}+1$ 个数的均值为这组数据的中位数。

类似地，下四分位数 Q_1 是排序后第 $\frac{n+1}{4}$ 个数据，上四分位数 Q_3 是排序后第 $\frac{3(n+1)}{4}$ 个数据, 若结果不为整数，则取相邻两数据的均值作为四分位数的值。

定义

定义 1.1.3 (方差 Variance)**.** 给定一组数据 $X_1, X_2, ..., X_n$，则

$$S^2 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}$$

称为这组数据的方差。

定义

定义 1.1.4 (标准差 Standard Deviation)**.** 给定一组数据 $X_1, X_2, ..., X_n$，则

$$S = \sqrt{\frac{\sum_{i=1}^{n}(X_i - \bar{X})^2}{n-1}}$$

称为这组数据的标准差。

1.2 推断

推断的目的是从数据中得出结论。结论需考虑数据中的自然变异性，因此正式的推断依赖于概率来描述随机变化。

我们将介绍两种最突出的正式统计推断方法：用于估计总体参数值的**置信区间**，以及评估对某个假设的可信度的**显著性检验**。这两种推断方法都基于统计量的抽样分布。

在一个典型的统计问题中，我们有一个感兴趣的随机变量 X，但其分布函数 $f(x)$ 或概率密度函数 $p(x)$ 是未知的。大致上，我们可以将其分为两种情况：

（1）非参数推断：$f(x)$ 或 $p(x)$ 完全未知；

（2）参数推断：$f(x)$ 或 $p(x)$ 的形式已知，但依赖于一个参数 θ（θ 可能是一个向量）。

参数是描述总体的数值，参数是一个固定的数字，但在实践中我们并不知道它的具体值。统计量则是描述样本的数值，当我们抽取一个样本后，统计量的值就已知了，但它会因样本的不同而发生变化。我们使用统计量来估计未知的参数。

1.3 估计

对于已知的样本，我们可以通过一定方法估计总体的统计量，我们主要介绍矩估计和最大似然估计（MLE）。

1.3.1 矩估计

定义

定义 1.3.1 (矩 Moment). 设 X 为随机变量，如果 $E[X^k]$ 存在（k 为正整数），则称 $E[X^k]$ 为随机变量 X 的 k 阶矩。

方法

通过令总体的 k 阶矩等于样本的 k 阶矩，我们可以得到总体参数的估计量。

Example

假设随机变量 X 均值与方差分别为 μ 和 σ^2，$X_1, X_2, ..., X_n$ 为已知样本。对于 X，我们有：

$$E[X] = \mu \ , \quad E[X^2] = Var[X] + \{E[X]\}^2 = \mu^2 + \sigma^2,$$

对于样本，我们有：

$$A_1 = \frac{1}{n}\sum_{i=1}^{n} X_i = \bar{X} \ , \quad A_2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2.$$

于是我们令：

$$\mu = \bar{X} \ , \quad \mu^2 + \sigma^2 = \frac{1}{n}\sum_{i=1}^{n} X_i^2,$$

可以解得估计量：

$$\hat{\mu} = \bar{X} \ , \quad \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

1.3.2 最大似然估计（MLE）

根据数据估计模型最常见的方法是通过似然估计。我们通过贝叶斯公式理解似然估计：

$$P(\text{Model}|\text{Data}) = \frac{P(\text{Data}|\text{Model})P(\text{Model})}{P(\text{Data})}.$$

我们想要得到 $P(\text{Model}|\text{Data})$，我们可以简介通过**似然函数**——$P(\text{Data}|\text{Model})$ 来接近它。

在似然函数中，数据被视为固定的，我们在所有可用的不同模型中寻找最佳的模型。

定义

定义 1.3.2 (似然函数 Likelihood)**.** 设 Y 为随机变量，其分布类型已知，但参数 θ 未知。记 Y 的概率密度函数为 $p_Y(y;\theta)$。
在给定数据 $y_1,...,y_n$ 后，参数 θ 的似然定义为：

$$L(\theta;y_1,...,y_n)=P_{Y_1,...,Y_n}(y_1,...,y_n;\theta)=\prod_{i=1}^{n}p_Y(y_i;\theta).$$

方法

通过求解使得似然函数最大时的参数 θ，我们可以得到参数 θ 的最大似然估计值。在具体计算中，我们一般：
(1) 写出似然函数 $L(\theta)=\prod_{i=1}^{n}p(y_i;\theta)$；
(2) 取自然对数，便于求导：$\ln L(\theta)=\sum_{i=1}^{n}\ln p(y_i;\theta)$；
(3) 求导并令导数为 0：$\dfrac{\mathrm{d}(\ln L)}{\mathrm{d}\theta}=0$；
(4) 解得估计值 $\hat{\theta}_{\mathrm{MLE}}$。

1.4 置信区间

对于未知量，我们除了要求得到近似值，通常还需要估计误差，即要知道估计值的精确程度。假设我们可以根据样本数据估计这个参数，并且我们知道这个估计量的分布，那么我们就可以利用它构造一个涉及估计量和参数真值的概率表述。通过数学处理，这个表述就可以转化为置信区间。

定义

定义 1.4.1 (置信区间 Confidence Interval)**.** 设 X 为参数为 θ 的随机变量。现有样本 $X_1,X_2,...,X_n$，对于给定值 $\alpha\in(0,1)$，如果由样本确定的两个统计量 $\hat{\theta}_1(X_1,...,X_n)$ 和 $\hat{\theta}_2(X_1,...,X_n)$ 满足：

$$P(\hat{\theta}_1(X_1,...,X_n)<\theta<\hat{\theta}_1(X_1,...,X_n))=1-\alpha,$$

则称区间 $(\hat{\theta}_1,\hat{\theta}_2)$ 为置信水平为 $1-\alpha$ 的置信区间。

分析

若反复抽样多次（每次抽样的容量都为 n），每个样本值确定一个区间 $(\hat{\theta}_1, \hat{\theta}_2)$，每个这样的区间要么包含 θ 的真值，要么不包含 θ 的真值。在这么多的区间中，包含 θ 的真值的约占 $100(1-\alpha)\%$，不包含 θ 的真值的约占 $100\alpha\%$。例如，若 $\alpha = 0.01$，反复抽样 1000 次，则得到的 1000 个区间中不包含 θ 真值的仅有 10 个。

Example

设总体 $X \sim N(\mu, \sigma^2)$，σ^2 已知，μ 未知，$X_1, X_2, ..., X_n$ 为已知样本。我们知道 $\bar{X}$ 是 μ 的无偏估计，且有：

$$\frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \sim N(0,1),$$

其不依赖于任何参数（称为枢轴量），则有：

$$P\left\{\left|\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}\right| < z_{\alpha/2}\right\} = 1-\alpha,$$

即

$$P\left\{\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2} < \mu < \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\right\} = 1-\alpha.$$

这样我们就有了 μ 的一个置信水平为 $1-\alpha$ 的置信区间：

$$\left(\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\right).$$

类似地，我们有方差 σ^2 未知时，均值 μ 的置信水平为 $1-\alpha$ 的置信区间：

$$\left(\bar{X} - \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1), \bar{X} + \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1)\right),$$

以及 μ 未知时，方差 σ^2 的置信水平为 $1-\alpha$ 的置信区间：

$$\left(\frac{(n-1)S^2}{\chi^2_{\alpha/2}(n-1)}, \frac{(n-1)S^2}{\chi^2_{1-\alpha/2}(n-1)}\right).$$

1.5 假设检验

对于总体的分布函数完全未知或只知道形式的情况，为了推断总体的某些位置特性，我们需要提出一些关于总体的假设，然后我们需要根据样本对所提出的假设作出是接受还是拒绝的决策。

定义

定义 1.5.1 (零假设 Null Hypothesis)**.** 假设检验的第一步是陈述一个我们试图寻找证据以反对的假设，称为零假设 H_0，显著性检验旨在评估证据反对原假设的强度。
通常原假设是一个“无效应”或“无差异”的假设。而我们想要寻找证据支持的主张被称为备择假设 H_1。

方法

假设检验的基本步骤包括：
(1) 确定原假设 H_0 和备择假设 H_1，两者对立；
(2) 从样本中构造一个用于检验的统计量，其抽样分布在 H_0 成立时是已知的；
(3) 在 H_0 成立的前提下，计算观测到当前样本结果的概率，我们称为 P 值；
(4) 设定显著性水平 α，作为判断是否拒绝 H_0 的阈值；
(5) 得出结论：如果 $P < \alpha$，则拒绝 H_0；如果 $P \geq \alpha$，则无法拒绝 H_0。

Example

已知人类总体的平均 IQ 为 100，标准差为 15，且我们有一个容量为 30 人的样本，样本中的受试者被要求吃坚果。一段时间后，我们发现他们的 IQ 为 107.5。现在我们要判断吃坚果能不能提高人的 IQ。
我们作出零假设 H_0：吃坚果不会提高人的 IQ。挑选统计量：

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} = \frac{107.5 - 100}{15/\sqrt{30}} = 2.739,$$

也就是说，P 值就是标准正态分布中 $z > 2.739$ 的概率，查表得到 $P = 0.0031$，与常用的显著性水平 $\alpha = 0.05$ 相比，$P < \alpha$，即拒绝原假设，选择备择假设：即吃坚果会提高人的 IQ。
根据研究问题的变化，如问题变为“吃坚果会不会**改变**人的智商”，我们要灵活选择单侧检验或双侧检验。