Bayesian Statistics 2026 Spring

第 3 讲：贝叶斯统计学

先验、似然、后验

整理：AmphiLuminism Fudan University

本讲摘要

本讲主要介绍贝叶斯方法的基本原理、它与频率派方法的区别、具体的数学推导公式、共轭先验的概念，以及在模型选择和假设检验中的应用。

在传统的参数化建模里，似然函数 $l(\theta|x) = f(x|\theta)$ 的意义在于：观测值 x 是已知的，参数 θ 是未知的，但它是确定的常数，只是我们暂时不知道它。通过最大化似然函数，我们可以求得：**在什么样的参数设定下，最容易发生我们看到的这个结果**。

贝叶斯派在这个基础上又往前走了一步：既然 θ 还没确定，我们可以把它**也看作一个随机变量，给它也加上一个分布（先验）**。

3.1 贝叶斯模型与先验 (Prior)

定义

定义 3.1.1 (贝叶斯模型 Bayesian Model)**.** 贝叶斯模型由一个参数统计模型 $(X, f(x|\theta))$ 和一个参数的先验分布 $(\Theta, \pi(\theta))$ 共同组成。其中。未知的参数 θ 现在被视为随机变量。

传统模型只需要知道数据是怎么产生的（即似然函数 $f(x|\theta)$）。贝叶斯模型则要求多一个维度：先验 $\pi(\theta)$。这意味着在做任何计算前，必须先声明对参数的“初始猜测”。如，一个人对陈述 $\boldsymbol{a}$ 拥有主观信念，而这份信念基于他拥有的知识 K，我们把这份信念写作 $P(\boldsymbol{a}|K)$，代表对这份信念的度量，也就是先验。

3.2 贝叶斯统计推断

定义

定义 3.2.1 (联合分布 Joint Distribution)**.** 基于贝叶斯模型，我们定义 (θ, x) 的联合分布：

$$\pi(\theta, x) = \pi(\theta) f(x|\theta).$$

它描述了参数和数据同时出现的概率。

定义

定义 3.2.2 (边缘分布 Marginal Distribution)**.** 我们定义 X 的边缘分布：

$$\pi(X) = \int \pi(\theta) f(x|\theta) \mathrm{d}\theta.$$

它是对所有可能的参数 θ 进行加权平均后的结果，代表了模型生成观测数据 X 的总概率，也称为**边缘似然**（marginal likelihood）或者**证据**（evidence）。

我们可以写出**贝叶斯公式**（Bayes' formula）：

定理

贝叶斯公式：

$$\pi(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{\int f(x|\theta)\pi(\theta)\mathrm{d}\theta}.$$

它代表了能从数据 x 中提取出的关于参数 θ 的全部信息。

· 先验概率（prior）$\pi(\theta)$ 是参数的概率密度函数，代表了在观测到数据之前已有的知识（或被告知的信息）。

· 似然函数（likelihood）$f(x|\theta)$ 是在给定参数的情况下观测到数据的概率，代表了当前可获得的观测数据。

· 后验概率（posterior）$\pi(\theta|x)$ 代表了在结合先验信息和观测数据之后所得到的知识。

3.3 共轭先验

定义

定义 3.3.1 (共轭先验 Conjugate Prior)**.** 如果先验分布与后验分布属于同一个分布族，那么这个先验分布就称为似然函数的**共轭先验**。

3.3.1 二项分布与 Beta 分布

在贝叶斯统计中，**Beta 分布**（Beta distribution）是一个非常重要的连续概率分布，因为它通常被用作二项分布中成功概率 p 的共轭先验。

定义

定义 3.3.2 (Beta 分布 Beta Distribution)**.** Beta 分布定义在区间 $[0,1]$ 上，其概率密度函数为：

$$f(x;\alpha,\beta)=\frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha,\beta)},$$

其中 Beta 函数的表达式为：

$$B(\alpha,\beta)=\int_0^1 t^{\alpha-1}(1-t)^{\beta-1}\mathrm{d}t.$$

Beta 函数保证概率密度函数归一化。

Beta 分布的性质包括：

（1）期望 $E[X]=\dfrac{\alpha}{\alpha+\beta}$；

（2）分布 $\mathcal{B}e(1,1)$ 即为 $[0,1]$ 上的均匀分布；

（3）如果二项试验的先验为 $\mathcal{B}e(\alpha,\beta)$，在观测到 s 次成功和 f 次失败后，后验分布变为 $\mathcal{B}e(\alpha+s,\beta+f)$。

Example

假设我们进行 n 次独立实验，成功次数为 x。这服从二项分布 $X|\theta\sim B(n,\theta)$，其中 θ 是成功的概率。在实验开始前，我们对 θ 一无所知，所以我们假设 $\theta\sim U[0,1]=\mathcal{B}e(1,1)$，我们有

$$P(X=x|\theta)=f(x|\theta)=C_n^x\theta^x(1-\theta)^{n-x}.$$

根据贝叶斯公式，我们有

$$\pi(\theta|x) = \frac{C_n^x \theta^x (1-\theta)^{n-x}}{\int_0^1 C_n^x \theta^x (1-\theta)^{n-x} \mathrm{d}\theta}.$$

归一化分母

$$\pi(x) = \int_0^1 P(X=x|\theta)\pi(\theta)\mathrm{d}\theta = \frac{1}{n+1}\ ,\ \text{for } x = 0, 1, ..., n.$$

我们得到后验：

$$\pi(\theta|x) = (n+1)C_n^x \theta^x (1-\theta)^{n-x} \sim \mathcal{B}e(x+1, n+1-x).$$

也就是说，如果抛了 10 次硬币，发现有 7 次正面朝上，且最初我们认为概率是均匀分布的，即 $\mathcal{B}e(1,1)$。那么实验后，我们对正面概率 θ 的认识就变成了一个 $\mathcal{B}e(8,4)$ 分布。

3.3.2 正态分布

对于正态分布，我们也可以通过观测到的样本更新对参数的认识。正态分布对应的共轭先验也是正态分布。

分析

考虑样本 $X_1|\theta \sim N(\theta, \sigma^2)$，参数 $\theta \sim N(m_0, \sigma_0^2)$，则有下面的正比关系：

$$\begin{aligned}\pi(\theta|x_1) &\propto f(x_1|\theta)\pi(\theta) \\ &\propto \exp\left(-\frac{(x_1-\theta)^2}{2\sigma^2} - \frac{(\theta-m_0)^2}{2\sigma_0^2}\right) \\ &\propto \exp\left(-\frac{1}{2\sigma_1^2}(\theta-m_1)^2\right).\end{aligned}$$

其中

$$\frac{1}{\sigma_1^2} = \frac{1}{\sigma_0^2} + \frac{1}{\sigma^2}\ ,\ m_1 = \sigma_1^2\left(\frac{x_1}{\sigma^2} + \frac{m_0}{\sigma_0^2}\right).$$

故我们有

$$\theta|x_1 \sim N(m_1, \sigma_1^2),$$

并且我们可以看到新的方差 σ_1^2 减小了。

我们可以通过已有的观测值 x_1 预测下一个观测值 $X|\theta \sim N(\theta, \sigma^2)$：

$$f(x|x_1) = \int f(x|\theta)\pi(\theta|x_1)\mathrm{d}\theta.$$

现在假设我们观测到 $X_2|\theta \sim N(\theta, \sigma^2)$，由于 x_1 和 x_2 是独立的，我们有

$$\begin{aligned}\pi(\theta|x_1, x_2) &\propto f(x_2|\theta)f(x_1|\theta)\pi(\theta)\\ &\propto f(x_2|\theta)\pi(\theta|x_1)\\ &\propto f(x_1|\theta)\pi(\theta|x_2).\end{aligned}$$

也就是说，当获得第二个数据 x_2 时，不需要从头开始计算，只需要把已经吸收了 x_1 信息的后验分布 $\pi(\theta|x_1)$ 当作新的先验，然后乘以新数据 x_2 的似然即可。这种方法可以推广到多个数据：

$$\pi(\theta|x_1, ...x_n) \propto f(x_n|\theta)\pi(\theta|x_1, ..., x_{n-1}).$$

可以这样理解：**n 时刻的先验就是 $n-1$ 时刻的后验**。

我们对比贝叶斯方法与最大似然方法：以正态分布为例，最大似然估计在 n 时刻为：

$$\theta_{\mathrm{ML}} = \arg\sup \prod_{i=1}^{n} f(x_1|\theta) = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

n 时刻的后验为：

$$\theta|x_1, ..., x_n \sim N(m_n, \sigma_n^2),$$

其中

$$\frac{1}{\sigma_n^2} = \frac{1}{\sigma_0^2} + \frac{n}{\sigma^2}\ ,\quad m_n = \sigma_n^2\left(\frac{\sigma_{i=1}^n x_i}{\sigma^2} + \frac{m_0}{\sigma_0^2}\right).$$

可以发现，当 n 趋近于无穷大时，$\sigma_n^2 \to \dfrac{\sigma^2}{n}$，$m_n \to \dfrac{1}{n}\sum_{i=1}^n x_i$.

也就是说，**当样本量足够大时，先验的影响会逐渐消失，贝叶斯方法与 MLE 的结论会趋于一致**。

3.3.3 多项分布与狄利克雷分布

狄利克雷分布是多项分布的共轭先验。变量 X 取值于有限集 $\{a_1, ..., a_n\}$，我们有一系列独立的观测结果 $(x_1, ..., x_m)$，并且我们想要估计参数 $\theta_i = P(a_i)$，$i = 1, ..., n$。

MLE 估计的结果取决于样本中值 a_i 出现的次数 N_i，即 $\hat{\theta}_i = N_i/m$。这在小样本情形下往往较不准确。

我们也可以使用贝叶斯方法。我们引入狄利克雷分布作为先验，它是 Beta 分布在多维下的推广。

定义

定义 3.3.3. 狄利克雷分布 $D(\alpha_1, ..., \alpha_2)$ 的概率密度函数为：

$$f(x_1, ..., x_{n-1}; \alpha_1, ..., \alpha_n) = \frac{1}{B(\boldsymbol{\alpha})} \prod_{i=1}^{n} x_i^{\alpha_i - 1},$$

其中 $x_1, ..., x_{n-1} > 0$ 且 $x_n = 1 - x_1 - ... - x_{n-1}$，$B$ 函数

$$B(\boldsymbol{\alpha}) = \frac{\prod_{i=1}^{n} \Gamma(\alpha_i)}{\Gamma\left(\sum_{i=1}^{n} \alpha_i\right)}, \ \boldsymbol{\alpha} = (\alpha_1, ..., \alpha_n).$$

狄利克雷分布的性质包括：

（1）期望 $E(x_1, ..., x_n) = \left(\frac{\alpha_1}{\sum_i \alpha_i}, ..., \frac{\alpha_n}{\sum_i \alpha_i}\right)$；

（2）如果有了一组观测值 $(N_1, ...N_n)$，后验分布依然是狄利克雷分布，其参数更新为 $D(\alpha + N_1, ..., \alpha_n + N_n)$；

（3）根据样本更新后的概率估计值为 $\left(\frac{\alpha_1 + N_1}{\sum_i \alpha_i + \sum_i N_i}, ..., \frac{\alpha_n + N_n}{\sum_i \alpha_i + \sum_i N_i}\right)$。

3.3.4 泊松分布与 Gamma 分布

Gamma 分布是泊松分布的共轭先验。假设观测值 $X_i \sim P(\theta)$，即：

$$f(x_i|\theta) = \frac{\theta^{x_i}}{x_i!} e^{-\theta}.$$

我们选择 Gamma 分布作为参数 θ 的先验：

$$\pi(\theta) = \mathcal{G}(\theta; \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta}.$$

结合 n 个独立观测值后，后验分布仍然是一个 Gamma 分布：

$$\pi(\theta|x_1, ..., x_n) \sim \mathcal{G}\left(\theta; \alpha + \sum_{i=1}^{n} x_i, \beta + n\right).$$

3.4 贝叶斯方法的假设检验

与频率学派的假设检验方法不同，贝叶斯方法的假设检验基于已有的观测。

方法

以似然函数为二项分布的情形为例。假设先验分布 $\pi(\theta) = U[0,1]$，且

$$P(X = x|\theta) = C_n^x \theta^x (1-\theta)^{n-x},$$

我们有后验 $\pi(\theta|x) = \mathcal{B}e(x+1, n+1-x)$。如果我们想要检验 $H_0 : \theta \geq 1/2$ 和 $H_1 : \theta < 1/2$，我们可以简单地对后验进行积分

$$\pi(H_0|x) = 1 - \pi(H_1|x) = \int_{1/2}^{1} \pi(\theta|x)\mathrm{d}\theta.$$

当 = 现在我们需要在 H_0 和 H_1 之间做出选择，我们使用**贝叶斯因子**。

定义

定义 3.4.1 (贝叶斯因子 Bayes factors)**.** 贝叶斯因子是两个假设的边缘似然之比：

$$\begin{aligned} B^\pi &= \frac{\pi(x|H_1)}{\pi(x|H_0)} = \frac{\int f(x|\theta)\pi_1(\theta)\mathrm{d}\theta}{\int f(x|\theta)\pi_0(\theta)\mathrm{d}\theta} \\ &= \frac{\pi(H_1|x)\pi(H_0)}{\pi(H_0|x)\pi(H_1)}. \end{aligned}$$

它衡量了数据对一个假设相对于另一个假设的支持程度，并部分消除了先验概率对结果的影响。它也可以看作是后验胜率与先验胜率的比值.

方法

我们通常使用**杰弗里斯判据**（Jeffery's scale of evidence）来衡量证据的说服力。

- 若 $\log_{10} B^\pi$ 在 0 到 0.5 之间，认为对 H_0 的证据强度很弱（poor）；
- 若 $\log_{10} B^\pi$ 在 0.5 到 1 之间，认为对 H_0 的证据强度中等（substantial）；
- 若 $\log_{10} B^\pi$ 在 1 到 2 之间，认为对 H_0 的证据强度强（strong）；
- 若 $\log_{10} B^\pi$ 大于 2，认为对 H_0 的证据强度是决定性的（decisive）。

贝叶斯推断在概念上简单，但在处理复杂、高维模型时，计算高维积分变得极其困难。

为了解决这些计算难题，我们将在后面介绍**蒙特卡洛方法**（Monte Carlo methods）。